

RAG Avançado: Arquitetura e Prática

Implementação de Sistemas de Recuperação de Dados com Qdrant e
Maritaca AI

Prof. Mestre: Willgnner Ferreira Santos

Evolução do Paradigma RAG

A transição do modelo "Naive" para arquiteturas avançadas foca na redução de ruídos e no aumento da precisão contextual em sistemas de IA Generativa.

| Limitações do RAG Naive



Ruído Contextual

Busca linear que recupera fragmentos irrelevantes, confundindo a resposta final da LLM.



Busca Superficial

Dependência de termos exatos na consulta, ignorando nuances semânticas e intenções do usuário.



Baixa Precisão

Ausência de refinamento pós-busca, resultando em recomendações menos assertivas e genéricas.


| O Ecossistema Tecnológico

Stack de Desenvolvimento

 **Qdrant:** Banco de dados NoSQL vetorial para alta performance.

 **Maritaca AI:** LLM nacional (Sabiazinho-4) para geração de texto.

 **Sentence-Transformers:** Modelos para bi-encoders e cross-encoders.



Fase 1: Pré-Recuperação

Otimização da consulta na "porta de entrada" do sistema.

Query Expansion

A Pré-recuperação utiliza a inteligência da LLM para expandir a pergunta original do usuário.


- Geração de sinônimos cinematográficos.
- Identificação de diretores e gêneros correlacionados.
- Melhoria da "densidade semântica" do vetor de busca.

Resultado: Maior abrangência na captura de dados no Qdrant.

Motor de Busca: Qdrant

Escalabilidade e persistência em bancos vetoriais.

Dados em Alta Dimensão




Arquitetura de Pontos

No Qdrant, cada filme do IMDb é tratado como um **Ponto (Point)** contendo:

- **ID:** Identificador único.
- **Vetor:** Embedding de 384 dimensões.
- **Payload:** Metadados (Título, Ano, Sinopse).


O uso de índices **HNSW** garante buscas em milissegundos mesmo em grandes volumes.

| Precisão do Modelo RAG



**Dados comparativos baseados em benchmarks de recuperação semântica e fidelidade contextual.*

| Pipeline de Execução




| A Matemática da Similaridade

Similaridade de Cosseno

Utilizada para calcular a proximidade entre o vetor da pergunta e o vetor do documento.

$$\text{similarity} = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$




Perguntas?

Obrigado pela atenção!

Willgnner Ferreira Santos

Disciplina: Banco de Dados Não-Relacional

| Image Sources




https://static.vecteezy.com/system/resources/previews/073/249/397/non_2x/digital-brain-neural-network-artificial-intelligence-neural-networks-data-processing-and-digital-connectivity-concepts-free-vector.jpg

Source: www.vecteezy.com




<https://www.xenonstack.com/hubfs/enterprise-data-pipeline.png>

Source: www.xenonstack.com



https://qdrant.tech/articles_data/what-is-a-vector-database/architecture-vector-db.png

Source: qdrant.tech



Thumbnail for https://machinelearningplus.com/wp-content/uploads/2018/10/3d_projection.png

Source: machinelearningplus.com
machinelearningplus.com