

RAG Avançado: Arquitetura e Prática

Otimização de Recuperação com Qdrant e Maritaca AI

Marco Antônio Soares de Brito

Do Naive ao Avançado

A evolução técnica para redução de alucinações e aumento da precisão semântica.

| Limitações do RAG Tradicional



Ruído Contextual

Busca linear que recupera documentos irrelevantes, poluindo a janela de contexto da LLM.



Busca Superficial

Dependência excessiva da exatidão dos termos da consulta original do usuário.




Baixa Fidelidade

Dificuldade em capturar nuances semânticas complexas sem refinamento pós-recuperação.

| O Ecossistema Tecnológico

Arquitetura Distribuída

-  **Qdrant:** Banco NoSQL vetorial para alta performance e escalabilidade.
-  **Maritaca AI:** LLM brasileira (Sabiazinho-4) para geração contextualizada.
-  **Sentence-Transformers:** Geração de embeddings e re-ranqueamento.



Fase 1: Pré-Recuperação

Inteligência aplicada antes da consulta ao banco.

Query Expansion

Utilizamos a Maritaca AI para enriquecer a pergunta original antes de vetorizá-la.

- ✓ Geração de sinônimos técnicos.
- ✓ Identificação de diretores/gêneros.
- ✓ Aumento da densidade semântica.

Impacto: O Qdrant recebe uma consulta muito mais rica e precisa.

Motor de Busca: Qdrant


Persistência e recuperação em milissegundos.

Pontos e Vetores no Qdrant


Modelagem NoSQL Vetorial

Cada filme do IMDb é inserido como um **Ponto** com:

- 📁 **Vetor:** 384 dimensões.
- 📄 **Payload:** Metadados detalhados.
- ⚡ **Índice HNSW:** Busca aproximada rápida.




| Ganho de Precisão Semântica



Dados baseados em testes de recuperação de contexto para os top 1000 filmes.

| Pipeline de Execução Completo




Similaridade de Cosseno

O Cálculo da Proximidade

Métrica fundamental para determinar quão próximos os vetores de busca e os documentos estão no espaço NoSQL.

$$\text{similarity} = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$




Muito Obrigado!

Marco Antônio Soares de Brito

Disciplina: Banco de Dados Não-Relacional


| Image Sources



Thumbnail for
www.vecteezy.com

https://static.vecteezy.com/system/resources/previews/067/183/502/non_2x/serene-blue-digital-brain-illustration-circuitry-neural-network-abstract-mind-cognitive-technology-peaceful-atmosphere-professional-digital-artwork-with-vibrant-colors-and-detailed-composition-vector.jpg

Source: www.vecteezy.com



Thumbnail for
medium.com

https://miro.medium.com/1*2_JmqapqhstGh2XFb06vnw.jpeg

Source: medium.com



Thumbnail for
generativeai.pub

https://miro.medium.com/v2/resize:fit:1280/1*1zJL187DwZJbuDt5BW6uQw.gif

Source: generativeai.pub



<https://machinelearningplus.com/wp-content/uploads/2018/10/soft-cosine.png>

Source: machinelearningplus.com