Visão Geral do Processo ETL e Modelagem NoSQL

Este processo detalha as etapas de transformação, limpeza, modelagem e validação de dados para um sistema NoSQL, culminando em uma migração e comparação de performance.

Bloco 1: Preparação e "Blindagem" (ETL Inicial)

Transformando arquivos brutos em formato de alta performance

Etapa 1

Instalação e Importação: Preparação das ferramentas essenciais (pandas, pyarrow, pymongo) para o processamento.

Bloco 1: Preparação e "Blindagem" (ETL Inicial)

Transformando arquivos brutos em formato de alta performance

Etapa 2

Verificação de Diretório: Confirmação da localização dos arquivos para garantir acesso sem erros.

Bloco 1: Preparação e "Blindagem" (ETL Inicial)

Transformando arquivos brutos em formato de alta performance

Etapa 3

Conversão Blindada: Função robusta que lê arquivos JSONL inconsistentes e os salva como Parquet.

Bloco 1: Preparação e "Blindagem" (ETL Inicial)

Transformando arquivos brutos em formato de alta performance

Etapa 4

Esquema Unificado: Garantia de que todas as colunas tenham o mesmo tipo de dado, padronizando para o banco.

Bloco 2: Tratamento e Limpeza (Data Cleaning)

- Tratamento de Produções: Anos convertidos para inteiros e remoção de produções com datas inválidas.
- Tratamento de Equipe: Padronização de nomes de papéis (diretor, ator) e eliminação de espaços/duplicatas.
- Criação de Índices: Geração de 'atalhos' no MongoDB para buscas rápidas por ID de produção.

Bloco 3: Modelagem Documental (O Coração do Projeto)

Esta etapa crucial foca na criação de um modelo de dados NoSQL eficiente. Um dicionário em memória (cache) é usado para buscas ultra-rápidas de IDs de pessoas, evitando milhares de consultas ao banco. A denormalização é aplicada, inserindo a equipe diretamente no documento da produção, simplificando e acelerando o acesso aos dados NoSQL.

BD_Producao_Artistica

- equipe
- equipe_clean
- equipe_raw
- pessoa
- pessoa_clean
- pessoa_raw
- producao
- producao_clean
- producao_raw
- producoes_com_participantes


```
_id: ObjectId('69d65c72728f077c25750029')
id_producao : "715190"
id_pessoa : "37497"
papel : "Nadine's Client"
```

```
_id: ObjectId('69d65c72728f077c2575002a')
id_producao : "715190"
id_pessoa : "124692"
papel : "nan"
```

```
_id: ObjectId('69d65c72728f077c2575002b')
id_producao : "715190"
id_pessoa : "258179"
papel : "Reporter"
```

- BD_Producao_Artistica
  - equipe
  - equipe_clean
  - equipe_raw
  - **pessoa** ...
  - pessoa_clean
  - pessoa_raw
  - producao
  - producao_clean
  - producao_raw
  - producoes_com_participantes
- admin

```
_id: ObjectId('69d65c3c728f077c2555878a')
id_pessoa : "2523"
nome : "Accardi, A.J."
```

```
_id: ObjectId('69d65c3c728f077c2555878b')
id_pessoa : "3205"
nome : "Acuna, Ramón"
```

```
_id: ObjectId('69d65c3c728f077c2555878c')
id_pessoa : "2725"
nome : "Achard, Olivier"
```

```
_id: ObjectId('69d65c3c728f077c2555878d')
id_pessoa : "156"
nome : "A., David"
```

- BD_Producao_Artistica
  - equipe
  - equipe_clean
  - equipe_raw
  - pessoa
  - pessoa_clean
  - pessoa_raw
  - **producao** ...
  - producao_clean
  - producao_raw
  - producoes_com_participantes
- admin
- config

```
_id: ObjectId('69d65c1f728f077c2545e90a')
id_producao : "70625"
titulo : "Campanile d'oro, Il"
ano : "1955"
tipo_id : "1"
```

```
_id: ObjectId('69d65c1f728f077c2545e90b')
id_producao : "76172"
titulo : "Caída libre"
ano : "1994"
tipo_id : "1"
```

```
_id: ObjectId('69d65c1f728f077c2545e90c')
id_producao : "97851"
titulo : "Crucea de piatra"
ano : "1993"
tipo_id : "1"
```

- BD_Producao_Artistica
  - equipe
  - equipe_clean
  - equipe_raw
  - pessoa
  - pessoa_clean
  - pessoa_raw
  - producao
  - producao_clean
  - producao_raw
  - **producoes_com_participan...**
- admin
- config
- local

```
_id: ObjectId('69cc542bd81bd2a577298fa7')
id_producao : 70625
titulo : "Campanile d'oro, Il"
ano : 1955
tipo_id : 1
▸ equipe : Array (9)
```

```
_id: ObjectId('69cc542bd81bd2a577298fa8')
id_producao : 76172
titulo : "Caída libre"
ano : 1994
tipo_id : 1
▸ equipe : Array (1)
```

```
_id: ObjectId('69cc542bd81bd2a577298fa9')
id_producao : 97851
titulo : "Crucea de piatra"
ano : 1993
tipo_id : 1
▸ equipe : Array (2)
```

Bloco 4: Validação e Performance

MongoDB (NoSQL)

Recupera Produção e Equipe em uma única leitura, otimizado para agregações e rankings. O comando 'Unwind' desconstrói listas para análises detalhadas.

PostgreSQL (SQL)

A recuperação de Produção e Equipe exige múltiplos JOINs, com potencial latência em volumes grandes. Migração final para comparação de performance.

Inserção em Lotes (Bulk Insert): Agrupamento de 500 mil registros para carga rápida, reduzindo o tempo de minutos para segundos.

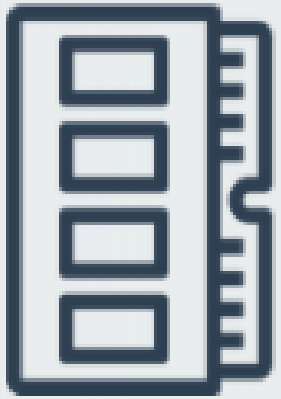

Dicionário de Pessoas em Memória: Mapeamento de IDs em RAM para evitar gargalos e milhares de consultas ao disco.

Esquema Unificado: Padronização rigorosa dos dados brutos inconsistentes para garantir consistência no banco.

	123 id_producao	A-Z titulo	123 ano	123 tipo_id
1	70.625	Campanile d'oro, Il	1.955	1
2	76.172	Caída libre	1.994	1
3	97.851	Crucea de piatra	1.993	1
4	86.809	Clinic, The	2.007	1
5	79.563	Chauffeur, The	1.921	1
6	84.114	Chyornyy kvadrat	1.988	1
7	2.718	20 Minuten Aufenthalt	1.960	3
8	76.511	Celestial Desires	2.003	4
9	99.261	Cultural Menace	2.004	1
10	14.301	Alex in Wonderland	1.970	1
11	3.967	360 grados en torno a Carmen Sevilla	1.972	3
12	53.504	Black Spot, The	1.917	1
13	29.603	Ask a Policeman	1.938	1
14	12.601	Air du temps, L'	2.004	1
15	67.826	Byeoksokui yeoja	1.969	1

	123 id_pessoa	A-Z nome
1	2.523	Accardi, A.J.
2	3.205	Acuna, Ramón
3	2.725	Achard, Olivier
4	156	A., David
5	360	Aaron, James
6	2.695	Aceves, Gustavo
7	2.970	Ackman, Felix
8	174	A.J.
9	163	A., Narayana Rao
10	786	Abbes, Mathias
11	1.624	Abesadze, Mikhail
12	2.836	Acid-Gruppe
13	3.520	Adamo, Jason
14	3.285	Adair, Arthur
15	601	Abarbanell, Eric

	123 id_producao	123 id_pessoa	A-Z papel
1	715.190	37.497	Nadine's Client
2	715.190	124.692	nan
3	715.190	258.179	Reporter
4	715.190	516.564	The Butler
5	715.190	683.371	Palace Guard
6	715.190	874.192	Man with Umbrella
7	715.191	22.384	Man
8	715.191	30.244	Officer #1
9	715.191	59.786	nan
10	715.191	78.882	Teammate
11	715.191	111.131	Mr. Orvac
12	715.191	112.755	nan
13	715.191	117.787	The vicar
14	715.191	123.253	Tailor
15	715.191	128.064	Mr. Vickers